GDPO：面向多奖励大模型强化的组奖励解耦归一化策略优化

Group reward-Decoupled Normalization Policy Optimization for Multi-reward RL Optimization

1. 背景

- 多维度目标优化：**正确性（Correctness）**、**格式规范（Format）**、**安全性（Safety）** 等。
- **GRPO** 在面对**多维异构奖励**时存在 **“奖励信号坍缩（Reward Signal Collapse）”** 问题。

GRPO 的缺陷：奖励坍缩与吞噬

在 GRPO 中，多维奖励被直接求和，然后进行组内归一化。这导致了两个致命问题：

1. **区分度丧失**：不同的奖励组合（如“对但啰嗦”和“错但简洁”）求和后可能总分相同，导致优势值（Advantage）完全一样，模型无法区分好坏。
2. **方差吞噬（Reward Swallowing）**：不同维度的奖励量纲（Scale）和方差差异巨大。

例如，密集的格式奖励（方差大）会掩盖稀疏的逻辑正确性奖励（方差小），导致模型为了迎合格式而牺牲逻辑正确性。

---

2. GDPO： 解耦归一化

先分别归一化，再求和。

对于给定的一个 Prompt，模型采样出 G 个回复构成一个组（Group）。假设我们设计了 M 种不同的奖励函数。

1. **独立奖励计算**：为每个回复分别计算 M 种奖励值。
2. **解耦归一化**：针对**每一种奖励**，独立地在组内计算其均值 μ_m 和标准差 σ_m，并转化为“子优势值”。
3. **聚合优势值**：将每个回复的所有子优势值相加，作为更新 Actor 网络的最终总优势值。

数学表达：

$$A_{total} = \sum_{m=1}^{M} \frac{r_m - \mu(r_m)}{\sigma(r_m)}$$

相比 GRPO 的 $A_{GRPO} = \frac{\sum r_m - \mu(\sum r_m)}{\sigma(\sum r_m)}$，GDPO 完美保留了每个奖励维度的细粒度梯度信号，彻底消除了量纲差异带来的影响。

---

3. 计算实例：GDPO vs GRPO

假设 Group Size $G = 3$，我们有两个维度的奖励： `correct` (正确性) 和 `format` (格式)。为了凸显量纲差异的危害，设定格式奖励的绝对值很大。

- **Rollout 1**: 答案对，格式对 ($r_{correct} = 1, r_{format} = 10$)
- **Rollout 2**: 答案错，格式错 ($r_{correct} = 0, r_{format} = 0$)
- **Rollout 3**: 答案对，格式错 ($r_{correct} = 1, r_{format} = 0$)

误区：使用 GRPO (先求和，再归一化)

1. **总奖励计算**： `[11, 0, 1]`
2. **组内统计量**：均值 $\mu = 4$，标准差 $\sigma \approx 4.96$
3. **优势值计算**：

- Rollout 1: $(11 - 4)/4.96 \approx 1.41$
- Rollout 2: $(0 - 4)/4.96 \approx -0.81$
- **Rollout 3:** $(1 - 4)/4.96 \approx -0.60$

结论：Rollout 3 明明逻辑完全正确，仅仅因为格式不对没拿到 10 分，就获得了**负向优势值**。这会惩罚模型的正确推理能力。

正解：使用 GDPO (先独立归一化，再求和)

1. $r_{correct}$ **独立归一化** (`[1, 0, 1]`):

- $\mu_c \approx 0.667, \sigma_c \approx 0.471$
- 子优势值 A_c: `[0.707, -1.414, 0.707]`

2. r_{format} **独立归一化** (`[10, 0, 0]`):

- $\mu_f \approx 3.333, \sigma_f \approx 4.714$
- 子优势值 A_f: `[1.414, -0.707, -0.707]`

3. **聚合总优势值 ($A_c + A_f$)**:

- Rollout 1: $0.707 + 1.414 = \mathbf{2.121}$
- Rollout 2: $-1.414 - 0.707 = \mathbf{-2.121}$
- **Rollout 3**: $0.707 - 0.707 = \mathbf{0}$

结论：在 GDPO 下，Rollout 3 的优势值为 0，逻辑正确的正向信号与格式错误的负向信号完美抵消，正确性梯度得以保留。

---

4. 条件奖励

在多目标强化学习中，常常面临 **“简单奖励主导（Easy Reward Dominance）”** 的问题（即 Reward Hacking）。模型可能会发现写对格式（简单任务）比做对数学题（困难任务）容易得多，从而变成一个“只输出完美格式废话”的机器。

为了防止这种情况，GDPO 配合使用了**条件奖励（门控机制）**：将“困难奖励”作为获取“简单奖励”的前提。

门控公式：

$$r'_{easy} = r_{easy} \cdot \mathbb{I}(r_{hard} \geq \tau)$$

如果模型在核心任务（如正确性）上未达标（$\mathbb{I} = 0$），其辅助任务（如格式分）将被直接清零。这强迫模型必须优先攻克核心推理任务。

代码逻辑：

```
import torch
def compute_gdpo_advantages(
        correct_rewards: torch.Tensor, # shape: [batch_size, group_size]
        format_rewards: torch.Tensor, # shape: [batch_size, group_size]
        epsilon: float = 1e-8
) -> torch.Tensor:
        gated_format_rewards = format_rewards * (correct_rewards > 0).float()
```